Personal Memory

Documentație de proiect

Cerințe, designul sistemului, alternative și planul de implementare

Limba: Română

Ediție: 2026-10-01

Regula privind datele: GitHub și portofoliul conțin doar date sintetice. Conversațiile personale rămân în sistemul local.

Ghid ușor de parcurs pentru scop, cerințe, arhitectură, alternative existente, limite de confidențialitate și livrare pe etape.

Cuprins

Cerințe, domeniu și justificarea proiectului Personal Memory . . . 4

1. Rezumat . . . 4
2. Problema și contextul utilizatorului . . . 4
3. Obiective . . . 4
4. Non-obiective și limite . . . 5
5. Utilizatori și scenarii . . . 5
6. Cerințe funcționale . . . 5
7. Cerințe non-funcționale . . . 7
8. Arhitectură și principii . . . 7
9. Produse existente și justificarea construirii . . . 8
10. Valoarea și prezentarea în portofoliu . . . 8

Politica de date pentru GitHub și utilizare locală . . . 8

11. Faze de livrare și criterii de acceptare . . . 8
12. Riscuri și întrebări de validat . . . 9
13. Istoricul deciziilor . . . 10

Evaluarea soluțiilor existente pentru Personal Memory . . . 11

Cerințele proiectului . . . 11

Comparație . . . 11

Concluzie și decizie . . . 12

Valoare pentru portofoliu . . . 12

Surse consultate . . . 12

Sistem personal de memorie - design . . . 13

Scop . . . 13

Arhitectură propusă . . . 13

Separarea datelor . . . 13

Delimitarea datelor personale și GitHub . . . 13

Import ChatGPT fără presupuneri . . . 14

Căutare și knowledge graph . . . 14

Interfață . . . 14

Livrare incrementală . . . 14

În afara primei versiuni . . . 14

Criterii de acceptare pentru fundație . . . 14

Plan de implementare - Personal Memory . . . 15

Decizii de lucru . . . 15

Etape și criterii de acceptare . . . 15

Ordinea dependențelor . . . 17

În afara primei felii 17

Checklist - Personal Memory 18

Pregătire 18

Etapa 0 - Evaluare produse existente 18

Etapa 1 - Fundație și contracte 18

Etapa 2 - API și căutare lexicală 18

Etapa 3 - Import ChatGPT (când arhiva este disponibilă) 18

Etapa 4 - UI și Android în LAN 18

Etapa 5 - Căutare semantică 19

Etapa 6 - MCP și adaptoare 19

Etapa 7 - Sincronizare și recuperare 19

Cerințe, domeniu și justificarea proiectului Personal Memory

Versiune: 1.0 **Data:** 2026-10-01 **Stare:** direcția de dezvoltare proprie a fost confirmată de utilizator; livrare incrementală.
Documente conexe: Design de sistem, Comparația soluțiilor existente, Planul de implementare, Checklist.

1. Rezumat

Personal Memory este un sistem personal, local-first, care adună conversații și alte surse într-un depozit controlat de utilizator. Depozitul trebuie să rămână util independent de furnizorul AI sau de interfața folosită: ChatGPT, modele locale precum Qwen, gpt-oss-20b și Gemma 4, agenți/harness-uri precum OpenCode și Hermes ori o interfață proprie.

Sistemul păstrează sursele originale separat de conținutul normalizat, indexuri și concluzii generate. Permite căutare full-text și semantică, navigarea conversațiilor și relațiilor, urmărirea fiecărui rezultat până la sursă, precum și acces de pe PC Windows și Android. PC-ul este planificat ca gazdă și sursă principală de adevăr; telefonul poate deține o copie locală/cache pentru utilizare offline și sincronizare ulterioară în rețeaua de acasă.

Acesta este și un proiect de portofoliu: documentează o nevoie reală, alternativele evaluate, compromisurile, modelarea datelor, importul robust, proveniența, căutarea și integrarea mai multor clienți AI. Scopul nu este să pretindă că un produs propriu este superior în orice situație, ci să arate ce cerințe concrete rămân neacoperite de soluțiile existente și cum sunt rezolvate.

2. Problema și contextul utilizatorului

Istoricul util este dispersat în conversații și instrumente diferite. Memoria nativă a unui singur asistent nu oferă utilizatorului un depozit independent, ușor de auditat, exportat și refolosit de alt agent. O căutare obișnuită nu ajunge când utilizatorul își amintește ideea, nu formularea exactă; rezumatele fără surse pot deforma contextul; iar conectarea la un PC de acasă trebuie să țină cont de rețeaua LAN și de folosirea telefonului.

Utilizatorul lucrează pe Windows, păstrează proiectele pe **D:\AI**, folosește Android, are de regulă telefonul și PC-ul pe aceeași rețea de acasă și deține un depozit GitHub pentru proiect: victorarsenie/PersonalMemory. Arhiva de export ChatGPT a fost solicitată și poate sosi ulterior. Formatul nu este încă disponibil pentru inspecție.

3. Obiective

1. Un depozit de memorie aflat sub controlul utilizatorului, cu o copie canonică pe PC.
2. Conservarea byte-cu-byte a fișierelor brute primite, cu hash și metadate.
3. Indexuri și date derivate regenerabile, cu legătură către sursa care le justifică.
4. Căutare lexicală și semantică, cu filtre și rezultate citabile.
5. Explorarea conversațiilor, documentelor, entităților și relațiilor într-o hartă.
6. Folosire de pe Windows și Android; acces în LAN în prima etapă și suport offline pe telefon în măsura stabilită prin prototip.
7. API și adaptoare care permit reutilizarea aceluiași depozit de către aplicații și agenți diferiți.
8. Import ChatGPT fără presupuneri despre schema exportului; implementarea parserului începe doar după primirea și inspecția arhivei reale.
9. Includerea imaginilor și fișierelor atașate în depozitul local, cu păstrarea originalelor, legătură către sursă și acces pe PC/Android.
10. Documentarea diferențierii față de produse existente și prezentarea onestă a capabilităților implementate în portofoliu.

4. Non-obiective și limite

- Nu reconstruim un model lingvistic și nu încercăm să înlocuim ChatGPT, modelele locale Qwen, gpt-oss-20b și Gemma 4, sau agenții/harness-urile OpenCode și Hermes.
- Nu presupunem că o integrare MCP este disponibilă în toate aplicațiile ChatGPT; verificăm transportul, planul și clientul concret la momentul integrării.
- Nu inventăm structura exportului ChatGPT înainte de a o inspecta.
- Nu modificăm arhivele originale și nu promovăm automat extracțiile la fapte certe.
- Nu expunem PC-ul direct la internet și nu deschidem porturi în router ca setare implicită.
- Nu facem sincronizare bidirecțională fără identificatori, versiuni, jurnal și tratarea explicită a conflictelor.
- Nu construim din prima o aplicație Android nativă dacă un client web instalabil satisface cerințele măsurate; alegerea se face după prototip.
- Nu introducem o dependență de cloud pentru căutarea locală de bază.

5. Utilizatori și scenarii

5.1 Proprietarul depozitului

- Adaugă/importă o sursă și vede raportul de ingestie.
- Caută după cuvinte, concepte, interval de timp, proveniență sau entitate.
- Deschide citatul în contextul mesajului/documentului original.
- Revizuiește, confirmă sau corectează entități și relații derivate.
- Folosește sistemul de pe telefon în aceeași rețea; când PC-ul nu este disponibil, poate consulta copia locală disponibilă și sincroniza ulterior.
- Face backup și poate reconstrui INDEX/DERIVED din RAW.

5.2 Agent AI sau client extern

- Caută în baza personală printr-un API stabil ori prin MCP.
- Primește fragmente relevante cu metadate și proveniență, nu doar o afirmație fără sursă.
- În prima versiune, citește datele; orice operație de scriere necesită reguli explicite de autorizare și jurnalizare.

5.3 Import ulterior al exportului ChatGPT

- Utilizatorul furnizează arhiva.
- Sistemul inventariază fișierele și identifică structura reală, fără a șterge ori rescrie sursa.
- Importer-ul raportează fișiere recunoscute, ignorate sau necunoscute și mapează datele confirmate la schema canonică.
- O reluare a importului nu dublează conținutul; erorile sunt explicabile și corectabile.

6. Cerințe funcționale

F-01 - Surse și importuri

Fiecare ingestie are identificator, tip de sursă, momentul importului, versiune de adaptor și rezultat. Sursele pot proveni din arhive, documente, imagini, fișiere atașate sau importuri ulterioare. Un import păstrează originalele, descrie ce a procesat și permite reluare fără duplicate.

F-02 - Separarea datelor

- **RAW:** arhiva sursă și binarele originale ale imaginilor/fișierelor, read-only după ingestie, păstrate byte-cu-byte și identificate prin SHA-256.

- **INDEX:** model canonic, metadatele fișierelor și legăturile dintre atașamente, mesaje și surse; indici lexicali/vectoriali regenerabili.
- **DERIVED:** fragmente, text extras, miniaturi, OCR, embeddings, rezumate, entități, relații și afirmații. Fiecare rezultat derivat păstrează proveniența și versiunea procesorului/modelului.

Reindexarea șterge și reconstruiește numai structurile regenerabile, nu RAW.

F-03 - Proveniență și audit

Orice rezultat sau afirmație trebuie să poată indica sursa, conversația/documentul, mesajul/pasajul și poziția, când formatul o permite. Distinge între conținut original, extras automat, confirmat de utilizator și contestat/corectat. Păstrează istoricul transformărilor și al sincronizării.

F-04 - Căutare

Căutarea lexicală suportă expresii și filtre după dată, sursă, conversație, entitate și tip. Căutarea semantică folosește embeddings printr-un provider configurabil, ideal local, și se poate reface când se schimbă modelul. Rezultatele combinate arată fragmente relevante, scoruri utile, metadate și legături către contextul complet.

F-05 - Knowledge graph

Graful păstrează entități, relații și afirmații ca date derivate, cu provenance. Interfața permite explorarea de la un concept către conversațiile și pasajele justificative. Extracția automată rămâne marcată ca atare până la confirmare; contradicțiile nu sunt suprascrise în tăcere.

F-06 - API și MCP

API-ul versionat reprezintă contractul comun pentru UI și integrații. MCP expune inițial căutare și citire; fiecare rezultat include provenance. Scrierea prin agenți se activează separat, după definirea aprobării, validării și jurnalului de modificări. Adaptoarele pentru modelele locale Qwen, gpt-oss-20b și Gemma 4, precum și clienții/agenții ChatGPT, OpenCode și Hermes, sunt componente opționale și nu schimbă modelul de date.

Limită ChatGPT: documentația oficială OpenAI verificată la 2026-10-01 spune că aplicațiile MCP sunt disponibile numai pe web, nu pe mobil; ChatGPT se conectează la servere MCP remote, nu direct la un server local. Pentru un server în rețeaua privată, este necesar un Secure MCP Tunnel în produsele OpenAI care îl suportă. Disponibilitatea developer mode și a acțiunilor complete MCP depinde de plan și workspace. Prin urmare, UI/API-ul propriu pentru Android rămâne necesar; integrarea ChatGPT este o cale web opțională, nu singura interfață mobilă. OpenAI: Developer mode and MCP apps in ChatGPT.

F-07 - PC, Android și sincronizare

PC-ul găzduiește serviciul și copia principală. Android se conectează în LAN și poate păstra o replică/cache locală, inclusiv atașamentele sincronizate pentru acces offline. Sincronizarea transferă schimbări identificate/versionate și fișiere, poate relua transferuri întrerupte și detectează conflictele; nu pierde variante. Protocolul exact și clientul PWA versus nativ se aleg după prototip și verificarea cerințelor offline.

F-08 - Interfață

Interfața oferă căutare, listă de rezultate, vizualizare conversație/document cu salt la pasaj, hartă a entităților și relațiilor, inspector de provenance, stare de sincronizare și flux de import. Afișează imaginile și previzualizările de fișiere în contextul sursei și oferă acces la original. Interfața trebuie să facă vizibilă diferența dintre sursă și inferență.

F-10 - Imagini și fișiere atașate

Sistemul importă și păstrează fișierele/imaginile atașate conversațiilor și documentelor, inclusiv formatele pentru care încă nu există extractor. Fișierul original rămâne intact în RAW și primește hash, nume, tip MIME observat, dimensiune și proveniență către sursa și mesajul de origine, când aceste informații există. Atașamentul rămâne accesibil din contextul conversației pe PC și Android; interfața poate afișa imaginea sau o previzualizare acceptată și permite deschiderea/descărcarea originalului.

Textul se extrage și se indexează numai pentru formatele pe care procesorii configurați le suportă. Pentru imagini, OCR, descriere vizuală și embeddings vizuale sunt capabilități derivate opționale, preferabil procesate local. Fișierele

necunoscute sau imposibil de citit nu blochează importul: se păstrează, se leagă de sursă și pot fi găsite după nume/metadate. Miniaturile, OCR-ul și textul extras sunt regenerabile și nu înlocuiesc originalele. Transferul fișierelor către replica Android suportă reluarea transferurilor întrerupte și acces offline la elementele sincronizate.

Criteriu de acceptare: originalul poate fi deschis sau recuperat cu hash identic după import; atașamentul are legătură navigabilă către sursă; conținutul suportat poate fi căutat; tipurile necunoscute sunt păstrate și raportate.

F-09 - Backup, confidențialitate și portabilitate

Backup-ul include RAW, baza canonică și configurațiile necesare restaurării; indexurile regenerabile pot fi reconstruite. Accesul LAN este autorizat; nu se expun porturi publice implicit. Formatele exportabile și schema sunt documentate, astfel încât utilizatorul să nu fie captiv într-un singur client.

7. Cerințe non-funcționale

- **Local-first:** stocare și căutare de bază pe echipamentele utilizatorului; conectivitatea cloud nu este necesară pentru funcțiile centrale.
- **Siguranța sursei:** operațiile asupra INDEX/DERIVED nu alterează fișierele RAW.
- **Trasabilitate:** rezultate și relații explicabile prin provenance.
- **Interoperabilitate:** clientul AI se poate schimba fără migrarea depozitului canonic la un serviciu de memorie proprietar.
- **Reproductibilitate:** migrațiile și operațiile de inițializare/import sunt versionate și documentate.
- **Evoluție incrementală:** fiecare etapă produce o felie utilizabilă, cu contracte stabile și migrare clară.
- **Portabilitate:** schema și exporturile sunt descrise suficient pentru backup, audit și mutare.

8. Arhitectură și principii

8.1 Componente

1. **Data store local:** fișiere RAW și baza de date canonică pe PC.
2. **Ingestion/import adapters:** parsează surse cunoscute și raportează necunoscutele.
3. **Search/index service:** full-text și, ulterior, index semantic.
4. **API local versionat:** folosit de UI, telefon și clienți.
5. **UI de explorare:** browser/aplicație web instalabilă inițial; PWA versus nativ validat separat.
6. **Android replica/sync:** funcție incrementală, cu cache offline și rezolvare explicită a conflictelor.
7. **AI adapters:** MCP, embeddings și clienți specifici, izolați de nucleu.

8.2 Model de domeniu inițial

Entități candidate: **Source**, **ImportRun**, **Conversation**, **Message**, **Attachment**, **Document**, **Passage**, **Entity**, **Claim**, **Relation**, **Provenance**, **Embedding**, **SyncEvent** și **Revision**. Identificatorii, schema și stările exacte se stabilesc într-o decizie de arhitectură înaintea implementării nucleului.

8.3 Principii de proiectare

- Source of truth în depozitul utilizatorului, nu în indexul unui asistent.
- RAW nu este o zonă de cache și nu este recreată din date normalizate.
- INDEX și DERIVED sunt regenerate cu versiuni explicite de parser/model.
- Relațiile și memoriile derivate nu pierd citatele care le justifică.
- Interfețele sunt adaptoare; contractele de date sunt independente de ele.
- Nu se alege o tehnologie doar pentru familiaritate; dependențele se verifică în mediul Windows al utilizatorului și se consemnează.

9. Produse existente și justificarea construirii

Produsele evaluate includ Khoj, Open WebUI, AnythingLLM, Memos, Mem0 și Letta. Ele oferă capabilități utile pentru second brain, RAG, memorie de agent, graf ori MCP; de aceea proiectul nu trebuie să le reproducă automat ca UI sau runtime.

Comparația inițială, cu linkuri la documentația oficială și limite formulate ca „nu am identificat în documentație", este în documentul de evaluare. Ipoteza de lucru este că niciun produs documentat nu unește într-un singur depozit controlat de utilizator: RAW-ul arhivei reale, import ChatGPT adaptat după inspecție, provenance granulară, indexuri reconstruibile, graph explorabil, căutare mixtă și interoperabilitate PC/Android/agenți.

Prin urmare, direcția aprobată este **să construim nucleul care acoperă aceste goluri și să reutilizăm produse existente când reduc efortul fără să compromită proprietatea datelor și proveniența**. Dacă prototipul arată că o alternativă acoperă mai mult decât estimăm, aria proprie se restrânge. Decizia este revizitabilă pe dovezi, nu pe atașament față de implementarea proprie.

10. Valoarea și prezentarea în portofoliu

Proiectul poate demonstra:

- analiză de problemă și evaluare a alternativelor;
- arhitectură local-first cu responsabilități RAW/INDEX/DERIVED;
- pipeline de ingestie rezilient, idempotent și explicabil;
- provenance și modelare a datelor/grafului;
- căutare lexicală și semantică cu modele locale precum Qwen, gpt-oss-20b și Gemma 4;
- API/MCP și integrare multi-agent;
- acces PC/Android, LAN, sincronizare offline și tratarea conflictelor;
- decizii de confidențialitate, backup și portabilitate;
- livrare incrementală și documentație tehnică.

Demo-urile, capturile, fixture-urile și toate datele din repo-ul GitHub vor folosi exclusiv date sintetice. Conversațiile și arhiva reale ale utilizatorului se folosesc doar local în instanța Personal Memory. Nu se publică și nu se comit arhive, RAW, extrase, indexuri, embeddings, loguri, capturi sau rezultate care conțin date personale. Nu se afirmă că o funcție este completă până când există o demonstrație verificabilă.

Politica de date pentru GitHub și utilizare locală

- Repo-ul GitHub, inclusiv commit-urile și materialele de portofoliu, conține numai cod, documentație și date sintetice create special pentru demonstrații.
- Datele sintetice nu se obțin prin anonimizarea conversațiilor reale; se generează separat pentru a evita scurgeri prin detalii sau metadate.
- Arhiva ChatGPT și conversațiile personale se importă numai în instanța locală configurată de utilizator. Nu se copiază în directoarele urmărite de Git.
- RAW, INDEX, DERIVED, backup-urile, logurile de ingestie și artefactele generate din surse personale sunt locale și excluse din Git. Configurația repository-ului trebuie să asigure acest lucru înainte de importul real.
- Prototipurile, walkthrough-urile și materialele publice folosesc date sintetice. Corectitudinea importer-ului poate fi verificată suplimentar local, pe o copie a arhivei reale, fără publicarea conținutului, rezultatelor sau capturilor.
- Erorile și logurile nu trebuie să includă implicit textul mesajelor sau conținutul privat al fișierelor.

11. Faze de livrare și criterii de acceptare

Faza 0 - Evaluare și prototip de produse existente

- Completează evaluarea documentată și verifică practic cei mai apropiați candidați cu date sintetice.
- Decide dacă produsul existent devine UI/client, dacă se extinde un produs sau dacă nucleul propriu rămâne justificat.

• Acceptare: decizie bazată pe criterii și goluri observate, cu utilizatorul implicat la schimbări mari de scope.

Faza 1 - Fundație de date

• Stabilește repo instructions, runtime, layout RAW/INDEX/DERIVED, configurare ignorată de Git și baza/migrațiile.

• Acceptare: depozit gol inițializabil, schema versionată, demonstrarea invariabilității RAW prin operații de reindexare.

Faza 2 - API și căutare lexicală

• API versionat, CRUD controlat pentru surse/importuri, FTS și rezultate cu provenance.

• Acceptare: conținut sintetic poate fi introdus/căutat/deschis din contextul său de origine.

Faza 3 - Importer ChatGPT

• După primirea arhivei, inventariază formatele reale, inclusiv cum sunt reprezentate imaginile și fișierele atașate; păstrează arhiva brută local și implementează parser/adaptor pentru ceea ce s-a observat.

• Acceptare: raport complet, import reluabil, necunoscute păstrate/raportate, proveniență verificabilă și atașamente păstrate cu legătura către mesaj; verificarea pe copia arhivei reale se face numai local și nu se include în Git.

Faza 4 - UI PC/Android și graph

• Căutare, context, provenance, explorare grafică, acces LAN și cache/sync incremental.

• Adaugă galerie/previzualizare pentru imagini și fișiere suportate, acces la original și disponibilitate offline pentru atașamentele sincronizate.

• Acceptare: utilizare demonstrată pe PC și Android; fișierele se deschid din mesajul de origine, iar conflictele și transferurile incomplete sunt vizibile.

Faza 5 - Semantic search și modele locale

• Integrează modele locale precum Qwen, gpt-oss-20b și Gemma 4 prin runtime-uri compatibile.

• Provider embeddings local configurabil, metadate model/versionare, fuziune lexicală/semantică pentru textul extras din formatele suportate.

• OCR/descriere/embeddings vizuale pot fi adăugate ca procesare derivată locală, fără a înlocui imaginea originală.

• Acceptare: rezultate semantice provin din pasaje/atașamente identificabile; re-embedding nu schimbă RAW.

Faza 6 - MCP și clienți

• MCP read-only inițial; probează conexiunea în fiecare client vizat și documentează restricțiile transportului.

• Acceptare: căutarea/citirea întoarce surse/provenance; scrierea rămâne dezactivată până la autorizare explicită.

Faza 7 - Backup, securizare și hardening

• Procedură backup/restaurare, autorizare LAN, jurnal și opțional acces la distanță prin rețea privată.

• Acceptare: restaurarea datelor este demonstrată; fără expunere publică implicită.

12. Riscuri și întrebări de validat

• **Format export necunoscut:** se amână parserul până la arhiva reală; se începe cu interfața și contractul adaptorului.

• **Suport MCP diferit per client:** testare la momentul integrării; aplicațiile MCP ChatGPT sunt web-only și nu se conectează direct la un server local conform documentației OpenAI consultate. Clientul Android propriu rămâne o cerință separată; tunnel-ul privat se evaluează numai pe suprafețele OpenAI suportate.

• **Offline și replicare complexe:** prototip și măsurare înainte de alegerea PWA/nativ și protocol sync.

• **Inferențe inexacte:** stări de verificare și citate; utilizatorul păstrează controlul faptelor.

• **Creștere de scope:** faze cu criterii de acceptare și reutilizare de produse existente unde păstrează cerințele centrale.

- **Disponibilitatea modelelor locale:** nucleul funcționează lexical fără embeddings; providerul semantic poate fi configurat ulterior pentru Qwen, gpt-oss-20b, Gemma 4 sau alte modele compatibile.

13. Istoricul deciziilor

- **2026-10-01:** utilizatorul a confirmat PC-ul și Android ca dispozitive țintă, conectarea de regulă prin aceeași rețea de acasă, depozitul în **D:\AI\PersonalMemory**, GitHub pentru versionare, arhiva ChatGPT ulterioară și integrarea cu modelele locale Qwen, gpt-oss-20b și Gemma 4, precum și clienții/agenții OpenCode și Hermes.
- **2026-10-01:** utilizatorul a confirmat dezvoltarea proprie dacă produsele existente nu acoperă cerințele și a cerut ca motivația comparativă și valoarea adăugată să fie documentate ca proiect de portofoliu.
- **2026-10-01:** documentația OpenAI consultată confirmă că MCP apps sunt web-only, se conectează la servere remote, iar serverele din rețele private pot necesita Secure MCP Tunnel; accesul MCP mobil direct nu este presupus.
- **2026-10-01:** utilizatorul a stabilit că repo-ul GitHub va conține doar date sintetice pentru o posibilă publicare open source; conversațiile personale se folosesc exclusiv local în instanța creată.
- Exportul ChatGPT nu a fost încă inspectat; schema lui rămâne necunoscută.

Evaluarea soluțiilor existente pentru Personal Memory

Data verificării: 2026-10-01 **Scop:** să stabilim dacă un produs existent acoperă nevoia sau dacă proiectul propriu aduce valoare tehnică și de utilizare. **Notă:** comparația descrie capabilități documentate; absența unei funcții din documentația consultată nu dovedește că produsul nu o poate oferi prin extensii.

Cerințele proiectului

- PC-ul Windows găzduiește sursa de adevăr locală, iar telefonul Android o poate accesa în rețeaua casei.
- Datele importate originale se păstrează intacte separat de indexuri și date derivate.
- Căutarea lexicală și semantică întoarce proveniență verificabilă spre conversația/documentul sursă.
- Conversațiile și cunoștințele se explorează prin căutare și hartă relațională.
- Importer-ul ChatGPT se scrie după inspectarea arhivei reale, fără presupunerea formatului; imaginile și fișierele atașate trebuie păstrate și legate de mesajul sursă.
- Nucleul poate fi folosit ulterior de modele locale precum Qwen, gpt-oss-20b și Gemma 4, precum și de clienți/agenți precum OpenCode, Hermes și ChatGPT, prin adaptoare stabile.
- Importurile, indexurile și memoria derivată pot fi reconstruite din sursele păstrate; accesul mobil și backup-ul au un comportament clar.

Comparație

Produs	Ce acoperă bine conform documentației	Goluri față de cerința Personal Memory
Khoj	Second brain personal self-hosted; chat și căutare în fișiere, acces prin browser și aplicații; modele locale sau cloud. Documentație · Self-host	Nu am identificat în documentația consultată un importer dedicat arhivei ChatGPT cu păstrare RAW și provenance per mesaj sau o hartă conversațională completă cu proveniență. E candidatul cel mai apropiat pentru un prototip personal self-hosted.
Open WebUI	Knowledge bases/RAG, modele prin Ollama și API-uri compatibile, opțiuni locale; conectare la servere MCP prin Streamable HTTP. Knowledge · MCP	Este în primul rând interfață de chat și retrieval pentru colecții de documente. Documentația consultată nu descrie arhivă ChatGPT ca sursă imuabilă, provenance la nivel de mesaj și graph explorer ca un singur flux gestionat. Poate fi util ca UI/model client peste un backend separat.
AnythingLLM	Document management flexibil, documente atașate sau încorporate în RAG și alegerea de modele locale sau cloud. Documents · Models	Workspace/RAG nu echivalează automat cu un depozit canonic de conversații cu RAW păstrat, provenance fină și grafic relațional. Ar putea fi evaluat ca interfață/RAG existentă, nu presupus drept înlocuitor complet.
Memos	Aplicație self-hosted pentru notițe; server MCP integrat, cu operații de căutare/creare/actualizare pentru memo-uri. MCP	Potrivit pentru notițe personale și MCP, dar modelul documentat este memo-centric; nu am găsit fluxul complet de import arhivă conversațională, căutare hibridă și graf cu provenance cerut aici.
Mem0	Strat de memorie pentru agenți cu API de add/search, memorie semantică și opțiuni de graph memory. Overview · Graph memory	Rezolvă memoria agentului (fapte selectate/recuperate), nu arhivarea integrală și explorabilă a conversațiilor originale, cu RAW și proveniență pe fiecare rezultat. Util ulterior ca reper/adaptor, nu ca depozit de arhivă.

Produs	Ce acoperă bine conform documentației	Goluri față de cerința Personal Memory
Letta	Runtime pentru agenți cu stare și memorie persistentă; App Server self-hosted și integrare MCP în ecosistem. Self-hosted App Server · MCP	Este centrat pe agenți și conversațiile lor. Cerința noastră este un depozit personal interoperabil care rămâne canonic indiferent de agentul sau clientul folosit.

Concluzie și decizie

Niciunul dintre produsele evaluate nu documentează, dintr-o singură instalare, întregul flux cerut: arhivă ChatGPT importată după inspectarea formatului real, sursă RAW păstrată intact, indexuri reconstruibile, proveniență granulară, căutare lexicală și semantică, explorare relațională și utilizare comună de pe PC/Android și prin adaptoare MCP.

Prin urmare, proiectul propriu este justificat, cu două limite de scope:

1. Nu reconstruim de la zero componente generice care pot fi înlocuite. Evaluăm produse existente ca UI sau clienți de modele/MCP, în special Khoj și Open WebUI.
2. Construim nucleul distinctiv: depozitul canonic RAW/INDEX/DERIVED, importerul bazat pe arhiva reală, provenance, graph-ul și API-ul/adaptoarele interoperabile.

Valoare pentru portofoliu

Proiectul arată capacitatea de a formula și valida o nevoie, de a compara produse existente, de a proiecta limite clare între date brute și indexuri, de a implementa import reluabil și proveniență, de a integra căutare lexicală/semantică, de a oferi acces cross-device și de a expune API/MCP către mai mulți agenți. Documentația va include motivația, alternativele, arhitectura, deciziile și limitările demonstrate; nu va pretinde că oferă avantaje care nu au fost implementate și verificate.

Surse consultate

- Khoj: Overview, Self-host
- Open WebUI: Knowledge bases, MCP
- AnythingLLM: Documents, Model configuration
- Memos: MCP server
- Mem0: Memory overview, Graph memory
- Letta: Self-hosted App Server, MCP server

Sistem personal de memorie - design

Stare: direcția confirmată de utilizator la 2026-10-01 **Data:** 2026-10-01

Scop

Construim incremental un sistem personal de memorie accesibil de pe Windows și Android. PC-ul găzduiește serviciile și copia principală; telefonul păstrează o copie locală, cautabilă offline, pe care o sincronizează cu PC-ul când ambele sunt conectate la aceeași rețea Wi-Fi. Accesul din afara casei poate fi adăugat ulterior printr-o rețea privată precum Tailscale.

Sistemul trebuie să păstreze sursele intacte, inclusiv imaginile și fișierele atașate, să arate proveniența fiecărei informații și să poată alimenta ulterior modele locale precum Qwen, gpt-oss-20b și Gemma 4, precum și agenți/harness-uri ca OpenCode și Hermes. Integrarea ChatGPT este o țintă separată și opțională. La 2026-10-01, documentația OpenAI spune că aplicațiile MCP sunt web-only, nu mobile; ChatGPT se conectează la servere MCP remote, iar un server dintr-o rețea privată poate necesita Secure MCP Tunnel. Accesul și acțiunile disponibile depind de plan/client. Aplicația proprie Android rămâne calea mobilă directă. Sursa OpenAI.

Cerințele complete, scenariile, criteriile și justificarea de portofoliu sunt în documentul de cerințe. Comparația produselor existente este în evaluarea soluțiilor.

Arhitectură propusă

- **Windows host:** serviciu local cu baza de date principală, API versionat și căutare. Serviciul ascultă numai pe rețeaua locală configurată; accesul necesită asocierea/autorizarea telefonului. Nu se configurează redirecționare de porturi.
- **Android:** aplicație proprie, instalabilă, cu bază locală/cache pentru căutare offline și coadă de sincronizare. Prima versiune a clientului va fi aleasă între PWA instalabilă și aplicație nativă după verificarea cerințelor de offline și a mediului disponibil.
- **Sincronizare:** protocolul transferă modificări identificabile, cu versiuni și proveniență, între telefon și PC. Schimbările conflictuale nu se suprascriu în tăcere; se păstrează ambele variante și se marchează pentru rezolvare.
- **Clienți AI:** API-ul este contractul comun pentru aplicațiile proprii. Un adaptor MCP separat expune operații limitate de căutare/citire și, ulterior, scriere controlată. Integrarea ChatGPT se activează doar pe suprafețele și planurile care o suportă.

Separarea datelor

- **RAW:** arhivele și binarele originale primite/importate, inclusiv imagini și atașamente, păstrate byte-cu-byte și identificate prin hash. Nicio normalizare sau editare nu le modifică.
- **INDEX:** date normalizate pentru căutare și sincronizare, cu referințe către fișierele și înregistrările RAW de origine.
- **DERIVED:** text extras, miniaturi, OCR, fragmente, embeddings, entități, relații, rezumate și afirmații deduse. Acestea pot fi reconstruite sau marcate ca revizuite fără a modifica RAW; procesarea vizuală este opțională și preferabil locală.

Schema sursă de adevăr va include surse și importuri, conversații/documente, mesaje, persoane/entități, afirmații și relații, proveniență, fragmente de căutare și evenimente de sincronizare. Faptele extrase vor păstra referința exactă la sursa și pasajul care le justifică, precum și starea lor (derivat, verificat sau contestat).

Delimitarea datelor personale și GitHub

The GitHub repository and portfolio use synthetic data only. The user's real conversations and ChatGPT archive are used only in the local Personal Memory instance. Keep RAW, INDEX, DERIVED, backups, ingestion logs, and outputs derived from private data outside tracked Git content. Configure exclusions before importing the real archive. Synthetic demo data is generated independently, not by anonymizing the user's conversations. Importer validation against a copy of the actual archive may happen locally; its content and outputs are not published.

Import ChatGPT fără presupuneri

Nu codificăm un format de export anticipat. Importatorul va avea o interfață de adaptor și un flux în etape: inspectarea arhivei reale (lista fișierelor și structura observată), raportarea conținutului, maparea formatelor observate către un model canonic, apoi import idempotent. Arhiva originală se copiază în RAW înainte de procesare. Elemente necunoscute sunt raportate și păstrate, nu eliminate. Importul nu începe până când utilizatorul furnizează arhiva și formatul ei este inspectat.

Căutare și knowledge graph

Prima etapă de căutare folosește full-text și filtre după sursă, dată și entități. Căutarea semantică folosește embeddings generate local, printr-un adaptor de model configurabil; indexul vectorial este derivat și regenerabil. Graful de cunoștințe păstrează entități, relații și afirmații împreună cu proveniența lor. Extracția automată nu devine fapt verificat fără confirmare.

Interfață

Interfața Windows/Android oferă căutare, rezultate cu surse, vizualizarea conversațiilor/documentelor și a imaginilor/fișierelor atașate, explorarea entităților și relațiilor, stare de sincronizare și inspectarea provenienței. Editările și validarea afirmațiilor sunt acțiuni explicite. Interfața de pe Android folosește aceeași API și aceleași convenții de proveniență ca serviciile AI.

Livrare incrementală

1. **Contract și nucleu local:** schema, migrații, directoarele RAW/INDEX/DERIVED, proveniența și configurarea Windows.
2. **Căutare și API:** full-text, endpointuri versionate și contractul comun pentru clienți.
3. **Client Android și sincronizare LAN:** cache local, asociere sigură, sincronizare și căutare offline, inclusiv transferul fișierelor atașate pentru acces offline.
4. **Explorare și graf:** interfață de căutare/hartă și afirmații cu proveniență.
5. **Adaptoare AI:** MCP pentru clienții locali, embeddings locale și integrarea ChatGPT acolo unde este suportată.
6. **Import ChatGPT:** după sosirea arhivei, inspectare reală a formatelor conversațiilor, imaginilor și fișierelor atașate și implementarea adaptorului potrivit.

Fiecare felie rămâne utilizabilă și aditivă. Importul, indexurile și datele derivate trebuie să poată fi reconstruite fără pierderea sursei brute.

În afara primei versiuni

- Acces public la PC, porturi deschise pe router sau sincronizare printr-un cloud terț.
- Presupuneri despre structura arhivei ChatGPT.
- Promovarea automată a rezumatelor/entităților la fapte verificate.
- Scrieri autonome ale agenților fără proveniență și reguli explicite de autorizare.

Criterii de acceptare pentru fundație

- O sursă poate fi păstrată în RAW și urmărită prin hash și metadate de proveniență.
- Indexurile și datele DERIVED se pot reconstrui fără modificarea RAW.
- Modelul canonic și API-ul nu depind de un singur format de export sau de un singur model AI.
- Arhitectura distinge clar copia principală de pe PC, replica Android și conflictele de sincronizare.
- ChatGPT mobile nu este prezentat ca fiind conectat prin MCP cât timp această funcție nu este suportată.

Plan de implementare - Personal Memory

Data: 2026-10-01 **Bază:** **docs/superpowers/specs/2026-10-01-personal-memory-system-design.md** **Stare:** direcția de evaluare și dezvoltare proprie a fost aprobată de utilizator la 2026-10-01; implementarea se face incremental.

Documentația detaliată a cerințelor, scopului și valorii de portofoliu este în **docs/project/requirements-and-scope.md**.

Decizii de lucru

- Baza locală de pe PC este sursa de adevăr; importurile brute rămân nemodificate în RAW.
- INDEX conține date normalizate și indexuri regenerabile; DERIVED păstrează legături, rezumate și vectori cu proveniență către sursă.
- Înainte de a scrie cod, compară aplicațiile existente cu cerințele și încearcă configurația celei mai potrivite. Construim componente proprii doar pentru golurile confirmate. Dacă nucleul propriu rămâne necesar, varianta inițială este SQLite/FTS5 și API Python/FastAPI; runtime-ul se alege după verificarea mediului.
- Importer-ul ChatGPT va fi modular: întâi contractul și interfața adaptorului, apoi parserul concret numai după primirea arhivei reale și inspectarea structurii sale.
- Pentru Android se începe cu o interfață web instalabilă și accesibilă în rețeaua locală. Sincronizarea offline bidirecțională și aplicația nativă se decid după validarea prototipului și a cerințelor reale de utilizare.
- Modelele locale Qwen, gpt-oss-20b și Gemma 4, plus clienții/agenții ChatGPT, OpenCode și Hermes, se conectează prin adaptoare peste API-ul și modelul de date stabile; niciunul nu devine dependență a nucleului.
- Fiecare etapă păstrează provenance (sursa, locatorul, timpul importului, transformarea și identificatorii legați) și oferă operații de reindexare fără modificarea RAW.

Etape și criterii de acceptare

0. Evaluare de soluții existente (înaintea implementării)

Comparația inițială este documentată în **docs/research/existing-solutions-comparison.md**. Utilizatorul a confirmat că dezvoltarea proprie este potrivită dacă produsele existente nu acoperă cerințele și că motivația/comparația trebuie păstrate în documentația de portofoliu.

- Evaluează practic Khoj, Open WebUI, AnythingLLM și Memos față de cerințele prioritare: date locale, funcționare cu model local, Android/browser în LAN, import de arhivă, păstrarea RAW, proveniență, hartă relațională și MCP.
- Pentru 1-2 candidați, verifică documentația curentă și fă un prototip cu date fictive; nu importa arhiva ChatGPT reală înainte de a o inspecta.
- Criteriu: recomandare comparativă clară: (a) configurăm un produs existent, (b) îl folosim ca UI peste un depozit/API propriu, sau (c) implementăm nucleul, explicând golurile care justifică efortul.
- Verificare: walkthrough manual PC și Android unde este posibil; consemnează cerințele neacoperite și orice limitare de acces la ChatGPT/MCP.
- Direcția de bază proprie, cu reutilizarea produselor existente acolo unde ajută, este aprobată; rafinăm produsul concret și adaptoarele după evaluarea practică.

1. Fundație și contracte de date

- Inspectează mediul și documentația existentă; consemnează alegerile efective de runtime și structura directoarelor.
- Definește structura **RAW/**, **INDEX/**, **DERIVED/**, configurarea locală și regulile de backup.
- Definește schema inițială pentru surse, conversații, mesaje, binare/atașamente, entități, relații și provenance; folosește migrații versionate și stochează hash, nume, tip MIME și dimensiune.
- Criteriu: un depozit gol poate fi inițializat reproductibil; datele sursă nu sunt suprascrise de transformări sau reindexare.
- Verificare: revizuire manuală a schemei, directoarelor și instrucțiunilor de inițializare.

2. API local și căutare lexicală

- Adaugă endpoint-uri locale versionate pentru sănătatea serviciului, surse, căutare și citirea elementelor cu proveniență.
- Configurează SQLite FTS5 pentru căutare lexicală, filtrare și navigarea rezultatelor către sursă.
- Adaugă import generic documentat pentru conținut textual și metadate, fără a pretinde compatibilitate cu un export ChatGPT neinspectat.
- Criteriu: utilizatorul poate adăuga, căuta și deschide conținut indexat; fiecare rezultat indică sursa și locația sa.
- Verificare: walkthrough manual pe date sintetice clar etichetate, fără date personale reale. Prototipurile și fixturile comise/publicate sunt exclusiv sintetice.

3. Importer modular ChatGPT

- Definește interfața adaptorului, raportul de import și politica pentru fișiere repetate, atașamente și erori.
- După disponibilitatea arhivei, inspectează structura și documentația inclusă înainte de a implementa parserul concret.
- Inventariază atașamentele efectiv întâlnite; păstrează originalele byte-cu-byte, leagă-le de mesajele sursă și raportează formatele necunoscute fără să oprească importul.
- Păstrează fișierele originale exact; scrie extrasele și indexurile doar în zonele destinate.
- Criteriu: importul este reluabil/idempotent, raportează ce a acceptat sau respins și permite refacerea indexurilor din RAW.
- Verificare: validare locală, privată, pe o copie a arhivei reale, cu controlul numărului de elemente și al provenienței; datele și rezultatele nu intră în Git.

4. Interfață de explorare și acces Android în LAN

- Construiește UI pentru căutare, navigarea conversațiilor/surselor și inspectarea provenienței.
- Adaugă vizualizarea grafului ca strat de explorare peste entități și relații aprobate/derivate.
- Configurează acces local controlat, instrucțiuni clare pentru PC și telefon și comportament util când serverul nu este disponibil.
- Adaugă previzualizări pentru imaginile și fișierele suportate, acces la original și transferuri reluabile pentru atașamentele sincronizate offline.
- Criteriu: PC-ul și telefonul din aceeași rețea pot accesa sistemul; UI afișează sursa și legăturile fără a expune directoarele brute.
- Verificare: walkthrough manual pe PC și Android în rețeaua locală.

5. Semantic search și integrare locală

- Integrează modele locale precum Qwen, gpt-oss-20b și Gemma 4 prin runtime-uri compatibile; configurează embeddings printr-un provider interschimbabil separat, cu metadate de versiune.
- Stochează vectorii doar în INDEX/DERIVED și leagă fiecare vector de versiunea modelului și textul sursă.
- Adaugă căutare semantică și fuziune cu căutarea FTS, fără a cere un model cloud.
- Indexează text extras din formatele suportate; tratează OCR-ul, descrierea vizuală și embeddings vizuale drept procesări locale opționale în DERIVED.
- Criteriu: schimbarea modelului permite re-embedding fără atingerea RAW; rezultatele păstrează proveniența.
- Verificare: walkthrough manual cu un model local disponibil; dacă lipsește, documentează clar funcționalitatea amânată.

6. MCP bridge și adaptoare pentru agenți

- Publică un MCP bridge cu un set restrâns de operații read-only inițial: căutare, citire, hartă și provenance.
- Separă adaptoarele pentru ChatGPT și agenții/harness-urile OpenCode și Hermes de serverul și schema centrale; acestea pot apela modele locale precum Qwen, gpt-oss-20b sau Gemma 4.
- Adaugă operații de scriere numai după definirea autorizării, validării și jurnalizării modificărilor.

- Criteriu: clienții suportati pot găsi și citi aceleași date prin API/MCP, iar sursa fiecărui rezultat este vizibilă.
- Verificare: conectare manuală per client, după confirmarea suportului și setărilor clientului.

7. Sincronizare, securizare și backup

- Evaluează un model PC-authoritative cu replică/cache local pe Android și cozi pentru schimbări offline.
- Documentează autentificarea în LAN, expunerea minimă a porturilor, backup-ul și restaurarea.
- Ia în calcul acces de la distanță numai la cerere, printr-un tunel privat; fără port forwarding implicit.
- Criteriu: procedura de backup/restaurare și conflictele de sincronizare sunt explicate înainte de a activa sincronizarea bidirecțională.
- Verificare: walkthrough manual de backup și recuperare pe copii locale.

Ordinea dependențelor

Fundație → API și FTS → importer concret (după arhivă) și UI/LAN → semantic search și MCP → sincronizare/întărire. UI prototip poate începe după ce API-ul și modelul minim sunt stabile. Qwen, gpt-oss-20b și Gemma 4 sunt modele locale vizate; OpenCode și Hermes sunt clienți/agenți integrați ulterior.

În afara primei felii

- Interpretarea arbitrară a arhivei ChatGPT înainte de a o vedea.
- Expunerea serverului direct la internet.
- Scrierea autonomă a „amintirilor” de către agenți fără aprobare și provenance.
- Alegerea unui format de replicare Android înainte de a verifica performanța și experiența PWA în utilizarea reală.

Checklist - Personal Memory

Planul detaliat este în **plan.md**. Comparația inițială a produselor este în **existing-solutions-comparison.md**. Utilizatorul a aprobat direcția de a construi nucleul propriu unde soluțiile existente nu acoperă cerințele.

Pregătire

- [x] Confirmă repo-ul și specificația existentă.
- [x] Compară documentația produselor existente și consemnează golurile față de cerințe.
- [x] Utilizatorul a confirmat dezvoltarea proprie dacă nu există soluție completă; se reutilizează UI/adaptoare unde au sens.

Etapa 0 - Evaluare produse existente

- [x] Compară Khoj, Open WebUI, AnythingLLM, Memos, Mem0 și Letta cu cerințele prioritare.
- [ ] Prototip manual cu date fictive pentru candidații cei mai potriviți.
- [x] Recomandă nucleu propriu interoperabil; evaluează produse existente drept UI/clienți/adaptoare.
- [x] Direcția proprie aprobată de utilizator la 2026-10-01.

Etapa 1 - Fundație și contracte

- [ ] Inspectează runtime-ul disponibil și instrucțiunile repo-ului.
- [ ] Definește contractele RAW / INDEX / DERIVED și regulile de păstrare RAW.
- [ ] Definește schema inițială și migrațiile versionate, inclusiv metadatele binarelor atașate, hash-uri și legături la sursă.
- [ ] Documentează inițializarea și backup-ul local.
- [ ] Revizuire manuală de acceptare.

Etapa 2 - API și căutare lexicală

- [ ] API local versionat.
- [ ] Index FTS5 și provenance în rezultate.
- [ ] Import generic documentat, fără ipoteze despre exportul ChatGPT.
- [ ] Walkthrough manual cu date sintetice.

Etapa 3 - Import ChatGPT (când arhiva este disponibilă)

- [ ] Inspectează arhiva și inventariază formatele reale.
- [ ] Implementează adaptorul pe baza formatului observat.
- [ ] Păstrează RAW și asigură import repetabil cu raport de rezultate, inclusiv imagini/fișiere atașate și legăturile lor către mesaje.
- [ ] Verifică local și privat pe o copie a arhivei; nu include date sau rezultate în Git.

Etapa 4 - UI și Android în LAN

- [ ] UI de căutare, explorare și provenance.
- [ ] Hartă a entităților și relațiilor.
- [ ] Previzualizări imagini/fișiere, acces la original și acces offline la atașamentele sincronizate pe Android.
- [ ] Acces local de pe Android și mesaj când PC-ul nu e disponibil.
- [ ] Walkthrough manual PC + Android.

Etapa 5 - Căutare semantică

- [ ] Provider embeddings interschimbabil și metadate de versiune.
- [ ] Integrează modelele locale Qwen, gpt-oss-20b și Gemma 4 prin runtime-uri compatibile.
- [ ] Căutare combinată FTS + semantică.
- [ ] Walkthrough manual sau documentarea dependenței locale absente.

Etapa 6 - MCP și adaptoare

- [ ] MCP bridge read-only inițial.
- [ ] Adaptoare pentru ChatGPT și agenții/harness-urile OpenCode și Hermes.
- [ ] Validare și jurnalizare înainte de orice operație de scriere.
- [ ] Conectare manuală în fiecare client suportat.

Etapa 7 - Sincronizare și recuperare

- [ ] Proiectează replicarea PC-authoritative și tratarea conflictelor.
- [ ] Documentează accesul LAN și backup/restaurare.
- [ ] Walkthrough manual de restaurare.